MLOps – Defiende el servidor

Visualización 2 de 2-4

Suleily Estefania Moreno Contreras
Tomás Alejandro González Forero

27 de octubre de 2026

Resumen

Este proyecto construye un flujo reproducible para clasificar conexiones de red como normales ($label = 0$) o ataques ($label = 1$) con UNSW-NB15. Se auditaron los datos, se evitó fuga entre entrenamiento y validación, se compararon cuatro configuraciones en MLflow, se congeló una versión final, se publicó en Hugging Face y se evaluó una vez sobre el test completo.

1. Datos y preparación

Se usaron las particiones publicadas de entrenamiento (175.341 filas) y test (82.332 filas), ambas con 45 columnas y sin valores faltantes. La fuente de atribución es UNSW-NB15; la descarga reproducible proviene de un mirror fijado a commit. Los SHA-256 y la procedencia están en ‘evidencias/auditoria.json‘.

El objetivo es ‘label‘; se excluyeron ‘id‘, ‘label‘ y ‘attack_cat‘ de las entradas. ‘id‘ se conserva para trazabilidad. Las variables categóricas (‘proto‘, ‘service‘, ‘state‘) se codifican con ‘OneHotEncoder(handle_unknown=ignore)‘ y las numéricas se escalan con ‘StandardScaler‘, dentro del pipeline ajustado solo con entrenamiento.

La partición usa ‘GroupShuffleSplit‘, semilla 42 y 20 % de grupos de validación. Cada grupo es el hash exacto del vector de predictores; así, los predictores idénticos no cruzan de train a validation. El resultado fue 140.145 filas de entrenamiento y 35.196 de validación, con cero grupos compartidos. Se conservaron filas con etiquetas contradictorias dentro del mismo grupo. El test se auditó sin usar sus métricas para seleccionar modelo.

2. Experimentos

Las cuatro configuraciones usan las mismas particiones, semilla, pipeline y umbral 0,5. Ataque es la clase positiva; los denominadores cero se resuelven con valor 0.

Modelo	Recall	Precision	FPR	Macro-F1
Logística $C = 0,1$	0,9885	0,9210	0,1834	0,9202
Logística $C = 1$	0,9870	0,9244	0,1748	0,9226
Árbol, profundidad 12	0,9714	0,9519	0,1062	0,9378
Bosque, 100 árboles	0,9827	0,9471	0,1189	0,9415

Los cuatro run ID y matrices de confusión están en ‘evidencias/experimentos.csv‘ y ‘evidencias/mlflow/‘. El bosque aleatorio obtiene el mayor Macro-F1 y una precisión alta; el árbol tiene el menor FPR, pero menor recall y Macro-F1.

Recall mide la proporción de ataques detectados; precision, la proporción de predicciones de ataque que realmente son ataques; FPR, la proporción de conexiones normales marcadas erróneamente como ataque; y Macro-F1, el promedio del F1 de ambas clases. Estas métricas hacen visible el costo operativo de las falsas alarmas, que no queda reflejado en una sola accuracy.

3. v1, v2 y decisión

v1 es la regresión logística $C = 1$, umbral 0,5, commit ‘0b3cd416...‘, run ‘d5c932d1de7342a59fb754c384d9295d‘. v2 cambia de familia al bosque aleatorio de 100 árboles, profundidad 20 y mínimo 10 observaciones por hoja; commit ‘6428eb9...‘, run ‘423880e8c50744af8f47f60a5736a423‘.

La decisión se tomó solo con validación y quedó congelada antes del test: v2 mejora Macro-F1 de 0,9226 a 0,9415, precision y FPR frente a v1, a cambio de una reducción pequeña del recall (0,9870 a 0,9827). El umbral se mantuvo en 0,5 para ambos.

4. Evaluación final

v2 se evaluó una sola vez sobre las 82.332 filas del test. 'score_attack' es la probabilidad de la clase 1 y 'y_pred=1' cuando score $\geq 0,5$.

Recall de ataque	0,9921
Precision de ataque	0,7959
FPR	0,3118
Macro-F1	0,8470
Matriz [0,1]	[[25464, 11536], [357, 44975]]

El recall alto indica buena detección de ataques, pero el FPR aumenta respecto a validación. Además, 8.541 filas de test (10,37 %) comparten vector de predictores con entrenamiento. Esto, junto con el carácter histórico del dataset, limita la generalización a tráfico actual.

5. Reproducibilidad, limitaciones y entrega

v1 y v2 se descargaron por SHA completo desde Hugging Face y se probaron sobre 20 filas fijas de validation: las etiquetas coincidieron; la diferencia máxima de score fue 0 para v1 y $4,44 \times 10^{-16}$ para v2. La evidencia está en 'evidencias/recuperacion/'.

El remote DVC operativo es local ('/home/suleily/dvc-storage'); Google Drive no aceptó la cuenta de servicio en "Mi unidad" por falta de cuota. Por tanto, falta sustituirlo por un remote compartido autorizado y repetir la recuperación desde ese almacenamiento. También deben confirmarse permisos de lectura del docente y enviar un único mensaje por el canal del curso.

El código, evidencias, ZIP e instrucciones están en el repositorio de GitHub: https://github.com/tomas-gonzalez2006/defiende-el-servidor-mlops. Los modelos están en https://huggingface.co/suliely/defiende-el-servidor-modelos. El uso de IA y las contribuciones están declarados en 'entrega.md'.

El respaldo 'dvc-backup-20261027.zip' y 'DVC$_BACKUP.md$'$permitentrasladarlosobjetosDVCmanualmente.Esunasolucinde$
$elcierreformalrequiereunremoteservidoporredyunapruebaderecuperacinconpermisosdelecturadeldocente.$

Referencias

UNSW-NB15: https://research.unsw.edu.au/projects/unsw-nb15-dataset. Evidencias principales: 'auditoria.json', 'experimentos.csv', 'seleccion.json', 'metricas-test.json' y 'predicciones-test.csv'.