MLOps — Defiende el servidor

Grupo e integrantes

Visualización 2 de 2-4

Suleily Estefania Moreno Contreras

Tomás Alejandro González Forero

Objetivo

Clasificar conexiones de red como normales (label=0) o ataques (label=1) usando UNSW-NB15, con trazabilidad de datos, código, experimentos y modelos.

Datos y procedencia

Se utilizaron las particiones publicadas de entrenamiento (175.341 filas) y test (82.332 filas).
La fuente de atribución es UNSW-NB15 y la descarga reproducible provino de un mirror fijado a un commit. Los SHA-256 y la advertencia de procedencia están en evidencias/auditoria.json.

Integridad

Ambas particiones tienen 45 columnas, no presentan valores faltantes y comparten esquema. El entrenamiento contiene 68,1 % de ataques y el test 55,1 %. El análisis encontró duplicados por predictores y grupos con etiquetas contradictorias; se conservaron sin alterar.

Preparación y control de fuga

Variables

El objetivo es label. Se excluyeron id, label y attack_cat de las entradas del modelo. Las variables categóricas proto, service y state se codifican con OneHotEncoder; las numéricas se escalan con StandardScaler dentro del pipeline.

Partición

El CSV de entrenamiento se dividió con GroupShuffleSplit, semilla 42 y objetivo de 20 % de grupos en validación. Los grupos se definieron por hash exacto de predictores, excluyendo identificador y etiquetas.

Resultado

Train: 140.145 filas y 80.832 grupos. Validation: 35.196 filas y 20.208 grupos. Grupos de predictores compartidos entre ambos: 0. La asignación y sus hashes están en evidencias/splits.json.

Test

El test se auditó descriptivamente sin usar sus etiquetas para escoger modelo o umbral. Se observó solapamiento predictor entre entrenamiento y test en 8.541 filas (10,37 %), por lo que las conclusiones deben interpretarse con cautela.

Experimentos y selección

Diseño

Se compararon dos familias: regresión logística, árbol de decisión y bosque aleatorio. Las cuatro configuraciones usaron las mismas particiones, semilla 42, pipeline de preprocesamiento y umbral 0,5.

Resultados de validación

Logística C=0,1: recall 0,9885, precision 0,9210, FPR 0,1834, Macro-F1 0,9202. Logística C=1: recall 0,9870, precision 0,9244, FPR 0,1748, Macro-F1 0,9226. Árbol: recall 0,9714, precision 0,9519, FPR 0,1062, Macro-F1 0,9378. Bosque: recall 0,9827, precision 0,9471, FPR 0,1189, Macro-F1 0,9415.

v1 y v2

v1 es la regresión logística C=1. v2 es el bosque aleatorio de 100 árboles, profundidad 20 y mínimo 10 observaciones por hoja. v2 fue elegida solo con validación: mejora Macro-F1 y reduce FPR frente a v1, aceptando una pequeña reducción de recall.

Trazabilidad

Los cuatro run ID y métricas están en evidencias/experimentos.csv. La decisión está congelada en evidencias/seleccion.json, antes de la evaluación final.

Evaluación final y recuperación

Test completo

v2 se evaluó una sola vez sobre 82.332 filas con umbral 0,5. Recall de ataque: 0,9921. Precision: 0,7959. FPR: 0,3118. Macro-F1: 0,8470. Matriz de confusión [0,1]: [[25464,11536],[357,44975]].

Interpretación

El modelo detecta la gran mayoría de ataques, pero en test produce más falsos positivos que en validación. Esto puede reflejar cambio de distribución entre particiones y las limitaciones históricas del dataset.

Recuperación

En un entorno temporal nuevo se recuperaron datos con DVC, v1 y v2 por SHA completo desde Hugging Face, y se predijeron 20 filas fijas de validation. Las etiquetas coincidieron en ambas versiones; la diferencia máxima de score fue 0 para v1 y 4,44e-16 para v2.

Entrega, limitaciones y referencias

Artefactos

README.md y entrega.md documentan instalación, DVC, MLflow, Hugging Face y reproducción. Las evidencias incluyen auditoría, experimentos, selección, test y recuperación. Los modelos publicados están en suliely/defiende-el-servidor-modelos, ramas v1 y v2.

Limitaciones de entrega

El remote DVC operativo es local (/home/suleily/dvc-storage). Google Drive no aceptó la cuenta de servicio en Mi unidad por falta de cuota; por ello la recuperación compartida queda pendiente de un almacenamiento autorizado. No se incluyen tokens ni credenciales.

Conclusión

El pipeline es reproducible localmente y la versión final está identificada por commits, run ID, SHA del modelo y hash del dataset. Antes de entregar al docente debe configurarse un remote DVC compartido y verificarse el acceso de lectura.

Referencias

UNSW-NB15: https://research.unsw.edu.au/projects/unsw-nb15-dataset

Repositorio de código: https://github.com/tomas-gonzalez2006/defiende-el-servidor-mlops

Repositorio de modelos: https://huggingface.co/suliely/defiende-el-servidor-modelos